Content Guard 产品需求文档（PRD）

项	值
文档版本	v2.0（完整版，评审用）
产品状态	已上线（http://43.142.12.100/）；v1.1 判定纪律已于 2026-10-27 17:50 部署
读者	产品/设计/研发评审、面试官、未来的自己
最后更新	2026-10-27
一句话	给 1–3 人小商家的「发布前合规体检」：贴文案 → 逐句判断 → 指回条款 → 逐条改写 → 人工确认

> 本 PRD 是上线后补写的完整版。V1（流程图 + 低保真原型）在 `designs/prototype/`，用于和设计对齐；两版差异见附录 D。

---

1. 需求背景

1.1 三个背景点

无专人负责合规

1–3 人的小商家团队，老板往往同时是运营、客服和内容。没有合规岗，也没人逐条读《广告法》和平台规范。文案多是自写，或从商品详情页改写。

平台无明确理由

发布后被限流、下架，平台通常只给一句“涉嫌违规”，不指出哪一句、违反哪一条。商家只能靠猜：改一版、再发、再被拦。

违规成本高

违规的成本在发布之后才显现：一条笔记的流量、账号权重，以及“还要不要继续做”的信心。所以判断必须发生在发布前，而不是事后申诉。

1.2 用户与场景

项	内容
用户	1–3 人小商家 / 个体买手；不懂法条，但要“这版能不能发”
频率	检查 5–10 次/天；生成 1–2 次/天

项	内容
设备	手机为主，桌面用于集中改稿
非目标	MCN、品牌合规部、需要审批流和账号级数据的企业团队

三个核心场景：

1. **已有文案体检（主）**：文案已写好，发布前贴进来，逐句看哪句会出事。
2. **从零生成（次）**：没有文案，给卖点生成 3 版；生成结果必须已自检，不能“生成完再查”。
3. **改完确认**：按建议改完，确认并导出；查过即进历史。

证据来源：作者本人是第一个用户；`docs/log.md` 记录了真实反馈（如“检查出 2 处、改写冒出 3 处，数量对不上”）；另有 24 条真实笔记做评测。**没有外部用户访谈**，以上用户画像标为“待验证假设”。

1.3 替代方案

方案	能给什么	缺什么
人工自查 / 平台提示	有判断，但依赖经验	平台不说具体理由；不可追溯
词表类工具	命中敏感词	只给词，不给条款和改写；语境误报多
通用大模型	能写能改	结论不稳定、不能对账、不方便查看历史记录

我们的差异不在“能生成”，在“每条判断都能指回原句和条款，并且改动能对账”。

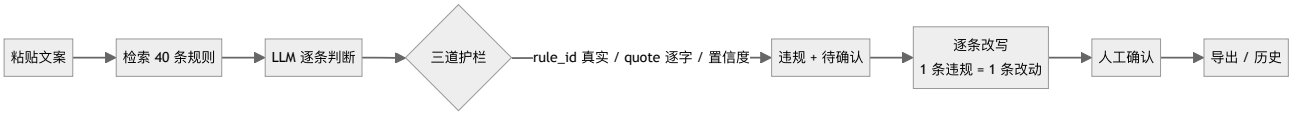
---

2. 需求概述

2.1 一句话定位

发布前的合规判断与修订，不是 AI 文案生成器。

核心链路四步：

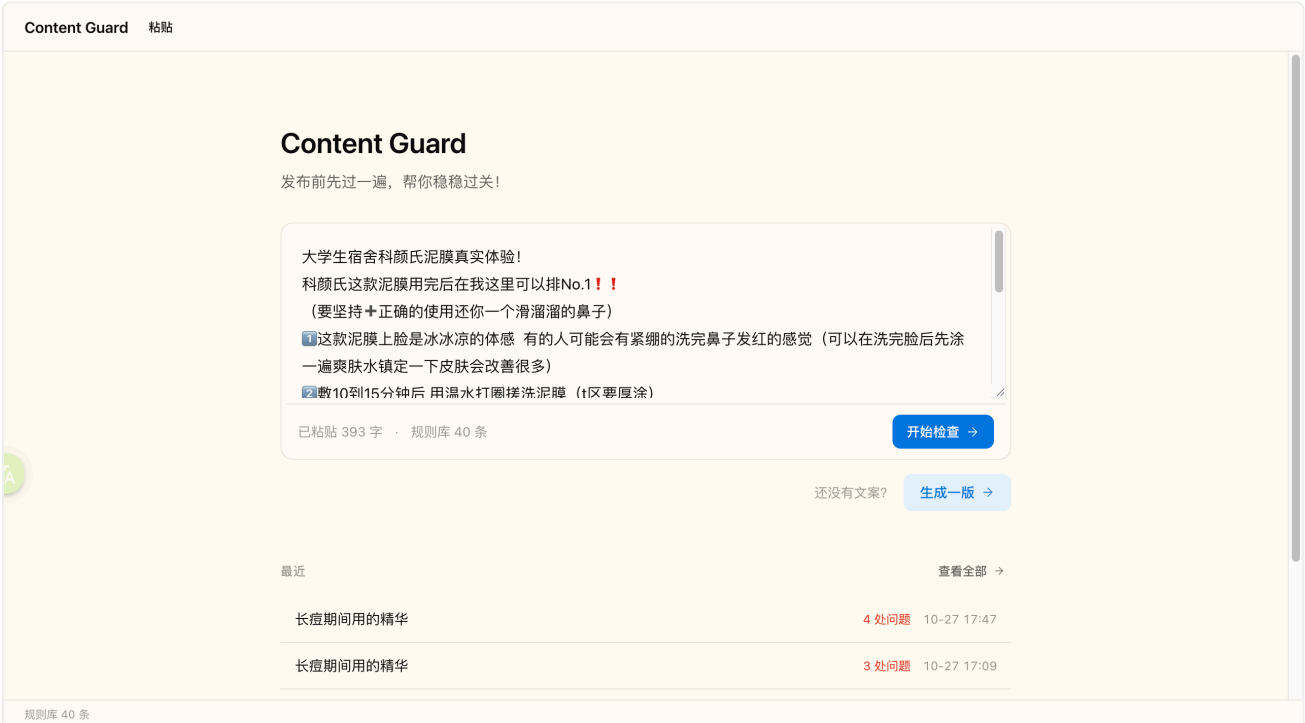


2.2 关键取舍

#	决策	理由	代价
1	检查功能是内核，生成功能只是辅助	高频动作是“这版能不能发”；生成功能不构成差异	生成入口权重低
2	生成即自检	不给用户“挖坑再卖梯子”；生成物直接就能发	一次生成最多 12 次模型调用
3	一次算完：检查 + 改写同一请求	两次请求结果可能会漂移，出现“检查 2 处、改写 3 处”的情况	单次 3 次调用；改写失败不能丢检查结果
4	改动数 = 违规数，编号 1:1	用户能逐条对照，不出现“多改一条”	改不了的只能标“未自动改写”
5	每条违规带条款原文和出处	合规要可审计；商家能自己复核	护栏会丢弃编造的 rule_id / quote
6	页面数字必须来自后端	假数字经不起考验	前端不能用默认值；mock 宁可不显示
7	不做登录，匿名设备号	降低门槛；demo 阶段不做账号体系	换浏览器看不到历史；header 可伪造

2.3 双入口与三栏工作台

- **入口 A 粘贴检查（主）**：首屏一个大输入框，按钮“开始检查”。
- **入口 B 从零生成（次）**：一行小字入口；生成 → 自检 → 自动改写 → 复检，通过才展示。
- **工作台三栏**：原文（红标 + 编号）｜诊断（规则、条款原文、建议）｜改写（蓝字 + 编号）。条款内联，不做抽屉；编号三栏共用。



首页：粘贴检查（真实笔记）



工作台：4 处违规，逐条改写（真实任务）

从零生成入口：



从零生成：填三样东西，生成 3 版



生成结果：3 版草稿，全部通过 40 条自检

---

3. 优先级划分

3.1 P0 · 已上线

- 粘贴检查 → 逐条判断 → 条款内联 → 逐条改写 → 确认导出
- 生成即自检（自检 + 自动改写 ≤2 轮 + 复检）
- 历史事件流 + 匿名设备号隔离；点开恢复
- 规则库 40 条（逐字可溯源）+ 规则校验 CI
- 限流 10 次/分钟；每日备份保留 14 天

3.2 P1 · 下一步

- 工作台“待确认”区：把 `uncertain` / `human_review` 展示出来（当前页面不展示）
- 检索修复：长文分段 / 按句召回，解决“规则在库里但没被召回”
- 规则 v2：按评测缺口补 5–8 条（普通食品功效、产地/等级举证、诱导关注口径）
- 部署 v1.1 判定纪律到线上

3.3 P2 · 远期

- 多平台（视频号 / 抖音）规则 adapter
- 图片 / 视频合规
- 账号级规则（推广占比、连发提醒）

- HTTPS + 自定义域名
- 团队版（多成员、审批流）—— 只在有真实需求后做

3.4 明确不做

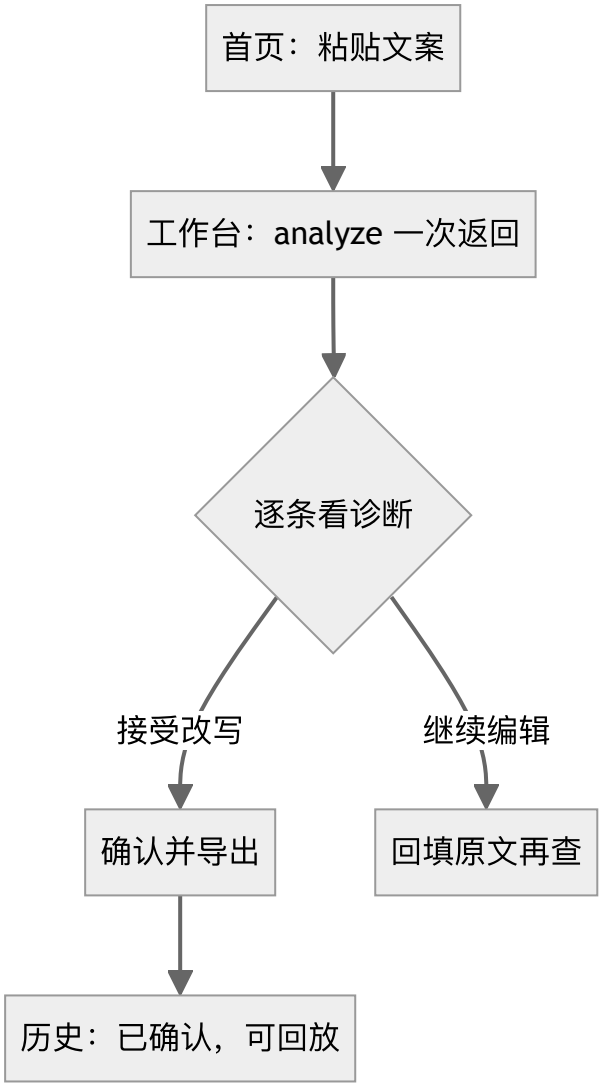
不做	原因
登录 / 多租户 / 权限	匿名设备号已够 demo；真账号 +1–2 天
支付 / 计费	商业化未验证，只写假设
模型微调	样本不足，规则一变就要重训；用 prompt
全量平台规则	维护不起；40 条可溯源 > 400 条不可溯源
自动发布到平台	需商家授权与平台审批，超出范围
图片 / 视频合规	本期只查文本
营销落地页	首屏就是工作入口
深色模式	P2，只预留 CSS 变量

---

4. 需求详情

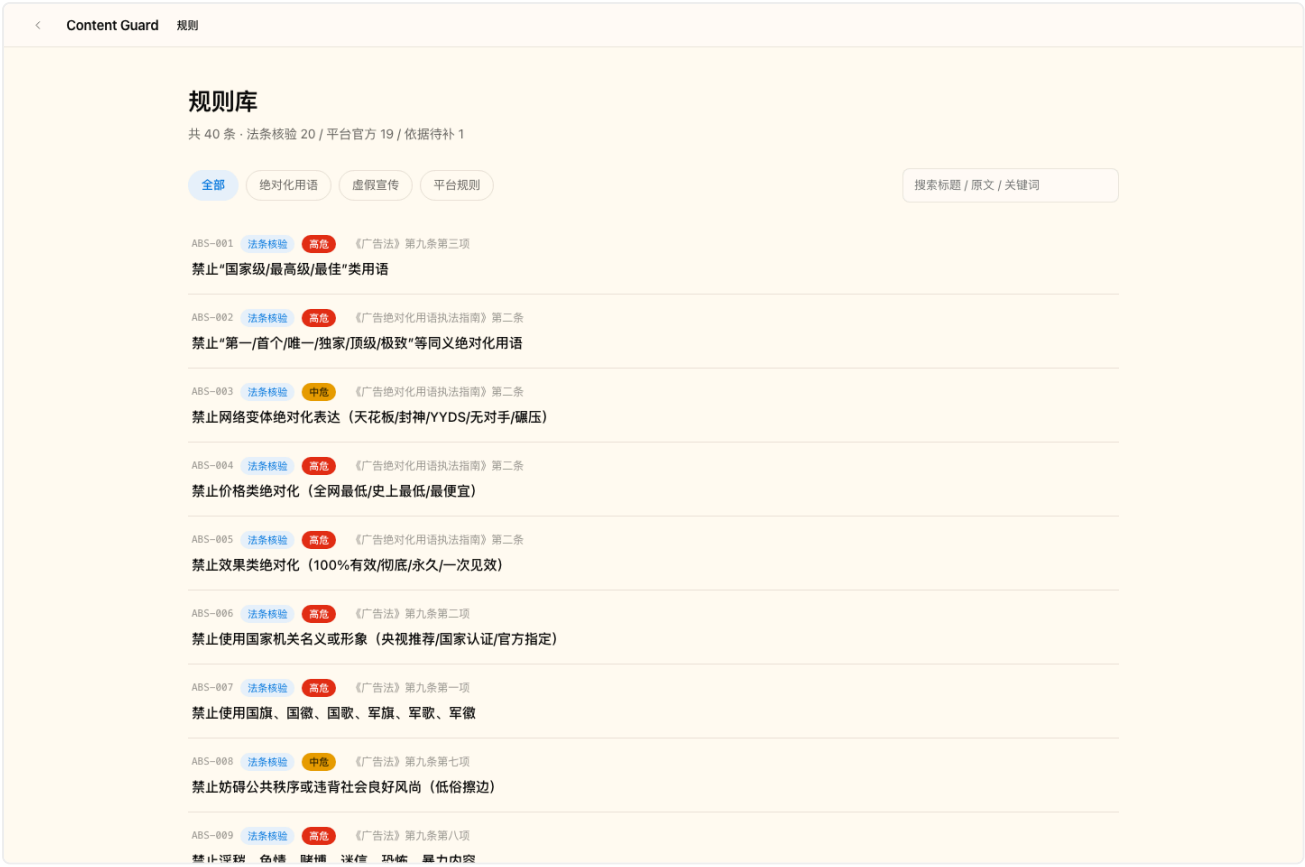
4.1 交互逻辑 / AI 需求

用户动线：



关键交互：

- 空内容回车 / 点检查 = 用示例跑，降低第一次使用门槛。
- 粘贴文案的标题 = 正文第一行；只当正文查一次，避免同一句查两遍。
- 工作台只渲染一次 `analyze` 的结果，不再发第二次改写请求。
- 每条违规可定位到原句；改不了的逐条标“未自动改写”，不编造。



规则库：40 条可溯源

4.2 功能详情

4.2.1 页面逻辑（用户动线）

入口页（粘贴 / 生成切换、最近记录）→ 工作台（三栏）→ 历史（事件流，点击恢复）→ 规则库（分类 / 搜索）。全局错误页给中文提示 + 重试。

4.2.2 前后端交互

页面只调 `POST /api/analyze`：取 owner → 建档 → 检查 #1 → 检查 #2 → 并集去重 → 逐条改写 → 写事件 → 返回。

确认走 `POST /api/confirm`（`UNIQUE(draft_id)` 幂等）；历史走 `GET /api/history`、`GET /api/events/{id}`。`/api/check`、`/api/rewrite` 保留给外部与评测，页面不再调用。

4.2.3 LLM 交互

- 一次 analyze = **两次独立检查 + 一次改写**（3 次调用）；两次检查取并集，每条都能指回原文。
- 三道护栏：`rule_id` 必须真实存在；`quote` 必须逐字出现在原文；`confidence < 0.7` 转 `uncertain`。
- 改写只回答“这条换成什么”，`start/end` 由服务端计算；改动数 = 违规数。
- 生成链路：生成 → 自检 40 条 → 命中则自动改写（≤2 轮）→ 复检 → 通过才返回。
- 失败兜底：JSON 三层解析；改写失败不丢检查结果（`rewrite_error`）；LLM 异常统一 504。

模块	功能	具体内容
入口	粘贴检查	大输入框 + 示例占位；空内容回车用示例；标题 = 正文第一行只查一次
入口	从零生成	卖点 / 价格 / 语气 → 3 版草稿；生成即自检，通过才展示
工作台	三栏	原文（红标 + 编号）/ 诊断（规则、条款、建议）/ 改写（蓝字 + 编号）
工作台	逐条改写	模型只给替换文本，服务端算 `start/end`；改不了标"未自动改写"
工作台	确认导出	幂等确认；导出最终文案 + 审核 ID
历史	事件流	查过即记；按匿名设备号过滤；点开恢复当次快照；越权 404
规则库	40 条可溯源	原文 + 出处 + 状态（法条核验 / 平台官方 / 待补）；分类与搜索
后端	`/api/analyze`	双检并集 → 逐条改写 → violations / uncertain / suspected / usage
后端	限流 / 备份	AI 接口 10 次/分钟；每日 SQLite 备份保留 14 天

4.3 埋点需求

现状（如实写）：只有后端日志，没有前端埋点。

- 每次请求一行 `llm_usage`：tokens、耗时、attempts、owner、violations 数；
- `events` 表记录 check / confirm，可查每条任务的状态；
- 响应带 `usage`，页面状态条显示真实数字。

缺口：入口点击、示例使用、`uncertain` 曝光 / 采纳、导出行为都没有前端埋点；没有漏斗和留存。

建议（P1，未实现）：事件 `page_view / analyze_start / analyze_success / analyze_fail / violation_shown / rewrite_accepted / confirm / export`；核心漏斗：检查完成率、确认率、改写采纳率、7 日回访。

---

5. 关键验收点

5.1 功能不变量

不变量	验收标准	怎么验
改动数 = 违规数	`len(violations) == len(rewrite.changes)`，`n` 一一对应	单测 + 真实请求
引用可定位	quote 逐字出现在原文；rule_id 存在；clause / source_url 来自 `rules.csv`	后端校验 + 评测引用正确率

不变量	验收标准	怎么验
改写可切片	`changes[i].start/end` 切出的文本 == `after`（unresolved 除外）	单测
数字可对账	页面 tokens / 耗时只来自接口 `usage`，无默认值	桩接口实测 + 日志对账
越权不暴露	别人的 draft / event 一律 404	单测 + curl
确认幂等	同一 draft 二次确认返回 `idempotent: true`，audit_id 相同	单测 + curl
限流可预期	第 11 次/分钟返回 429（JSON，不是 HTML）	连发 12 次 curl
备份可恢复	备份可解压、`integrity_check: ok`、行数与线上一致	恢复演练

5.2 指标验收

指标	定义	当前值（v1.1）	样本
严格召回	命中处数 ÷ gold 处数；rule_id 严格相等 + quote 归一化后相等/包含	**6/8（75%）**	8 处 gold
提示召回	gold 是否被提到（violations 或 uncertain，同句或同规则）	**7/8（87.5%）**	8 处 gold
误报率	（报出 − 命中 − 边界）÷（报出 − 边界）	**4/10（40%）**	10 条计分报出
精确率	命中 ÷ 计分报出	**6/10（60%）**	同上
引用正确率	quote 逐字 ∧ rule_id 存在 ∧ clause 一致	**18/18（100%）**	18 条报出

样本：24 条真实小红书带货笔记（001 + 002–024）；40 条规则冻结；gold = AI 按条款预标注 + 作者逐条确认，只有一致项进 gold；需要资质 / 语境的 24 处进边界，报对报错都不计分。

局限（必须一起读）：

- 24 条、8 处 gold，分母是个位数；只能说明方向，不能当“平台准确率”。
- 单一模型、单套 prompt、单次运行；没有跑第二遍，稳定性未知。
- 是在这 24 条上做错误分析后迭代的版本，有“对着这批题改”的风险。
- gold 不是法律意见；“什么算主观体验”仍有判断空间。
- 只测文本，不测图片 / 视频 / 账号级规则。

5.3 边界与 corner case

场景	处理
标题 = 正文第一行	只当正文查一次，避免同一句查两遍 / 只改标题不改正文

场景	处理
接口 schema 裁字段	Pydantic `response_model` 没声明的字段会被裁掉；加字段必须两边改
React Hook 顺序	所有 Hook 必须在提前 return 之前，否则整页 error #310
mock 与真接口字段名不一致	在数据层归一化（`text` vs `script`），UI 不直读后端
429 默认是 HTML	后端让 429 返回 JSON；前端加非 JSON 兜底
改写后的复检	不能当结论（指不回原句）；改为原文双检 + 逐条标注
老数据没有 owner	不归属任何人、不展示；按设计，不是 bug
备份保留策略测试	先 `touch -d` 又 `touch` 会把 mtime 改回现在，测试脚本自己会骗人
headless 截图窄屏	最小视口 500px；窄屏溢出要量 `innerWidth / scrollWidth`，不能看截图
中文时间格式	后端 ISO 带 `T`，显示前替换再截

附录

A. 规则来源与分布

- 40 条 = 法条核验 20（`verified`）+ 平台官方 19（`platform_official`）+ 待补 1（`platform_pending`）
- 类别：绝对化 10 / 虚假宣传 10 / 平台 20
- 唯一事实来源：`rules.csv`；`scripts/verify_rules.py` 逐字比对 `docs/sources/` 存档；CI 每次跑
- 不是全量规则："不全"在 UI 和本文档里如实写

B. API 与数据模型

- 9 个接口：health / generate / check / analyze / rewrite / confirm / history / events / rules
- 6 张表：products / drafts / checks / confirmations / events / rules
- 页面只用 analyze / confirm / history / events / rules；check、rewrite 保留给外部与评测

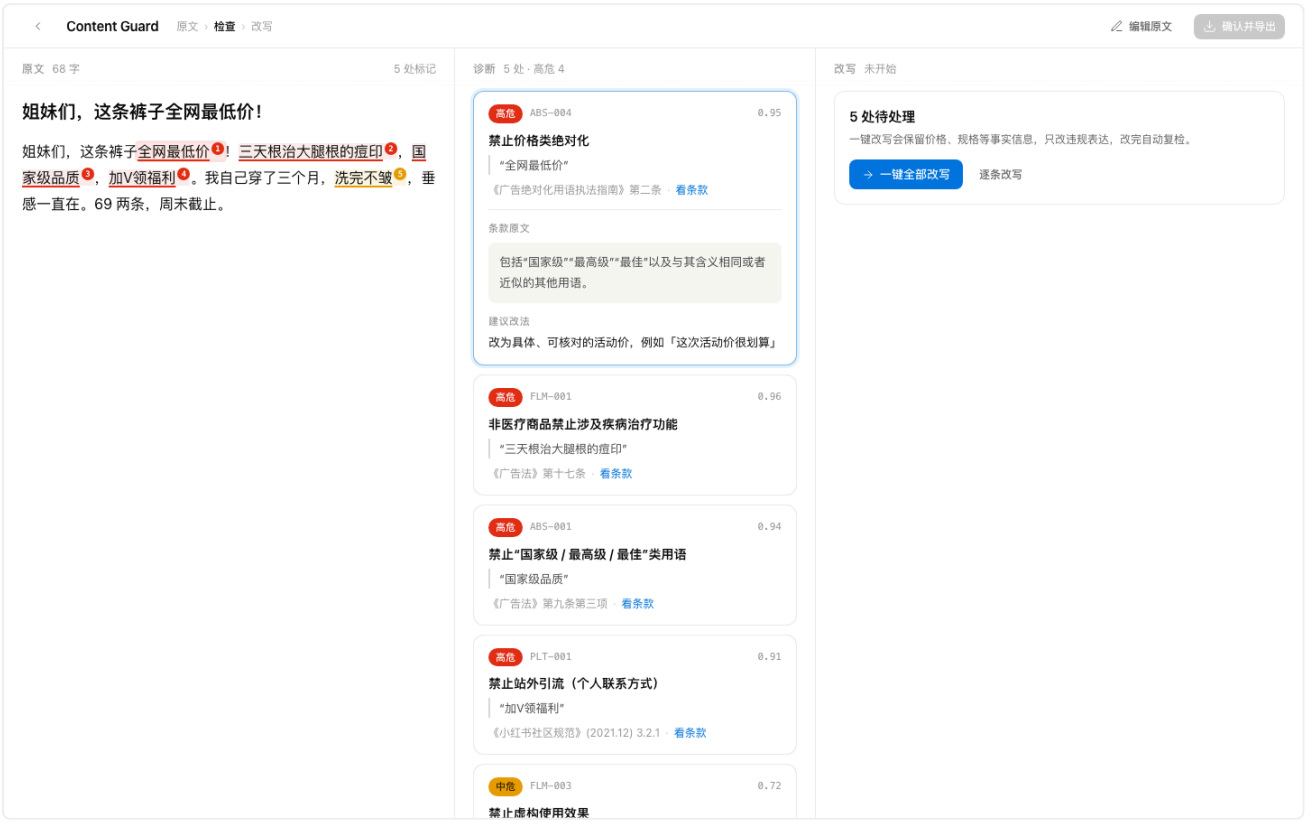
C. 评测方法与复现

- 样本：`data/eval_cases/`；标注表：`eval/label-sheet.md`；数据：`eval/results-v1.1.md`；报告：`eval/report-v1.md`
- 复现：`backend/.venv/bin/python eval/run_eval.py --out eval/results-v1.1.md`（或 `--from-raw` 零成本重算）
- 成本：24 条一轮约 1 元；未在仓库里写死价格

D. 文档索引与版本

文档	用途
`docs/decisions.md`	ADR-001~011，所有“为什么这么选”
`docs/handover-D3.md`	接手入口、进度、坑
`docs/log.md`	每日做了什么、真实反馈、事故
`eval/report-v1.md`	评测方法与错误归因
`designs/prototype/`	V1 流程图 + 低保真原型（本 PRD 之前）

V1 原型（设计对齐用）：



V1 低保真原型：工作台